Vinheria Agnello

Previsão de conclusão de compra em uma base simulada

1. Base de dados

O CSV oficial usado na modelagem contém **999 tentativas de compra** e **16 colunas**. Cada linha descreve uma tentativa associada a um produto. Os campos em negrito na tabela são as oito entradas do modelo.

Dimensão	Colunas e significado
Cliente	costumer_id (identificador), **costumer_profile** (perfil), **costumer_country** (país), **costumer_age** (idade) e **is_costumer_afiliated** (afiliação).
Relacionamento	costumer_days_since_last_sale (dias desde a última compra) e **used_virtual_sommelier** (indicador de uso do Sommelier Virtual).
Produto	product_id (código), product_label (nome), **product_category** (categoria) e product_review_score (nota de avaliação).
Oferta e período	**price** (preço original), **discount_percentage** (desconto), final_price (preço após desconto) e date (data da tentativa).
Rótulo	did_costumer_finish_sale (1 para compra concluída e 0 para não concluída).

2. Modelagem supervisionada

Escolhemos uma **árvore de decisão** porque seus cortes podem ser inspecionados e explicados. As entradas descrevem cliente, categoria de produto, condições da oferta e uso do Sommelier. Perfil, país e categoria foram codificados com OneHotEncoder dentro da pipeline. Afiliação e uso foram representados por 0 e 1. O momento do uso do Sommelier não é verificável no CSV.

O identificador de cliente serviu para agrupar as tentativas. Excluímos o preço final, derivado do preço e do desconto, e evitamos campos redundantes ou sem comprovação de disponibilidade antes da previsão.

> **Treino** 780 registros de 144 IDs **Teste** 219 registros de 36 IDs
> Nenhum ID aparece nos dois conjuntos. A seleção de hiperparâmetros usou cinco folds por grupo apenas no treino, com F1 macro como critério. O teste foi reservado para a avaliação final.

A árvore selecionada teve profundidade 1 e pesos de classe balanceados. Seu único corte usou o percentual de desconto. O desempenho no teste está na página 3.

3. Dashboard

Quatro visualizações principais com filtros de período, produto e país.

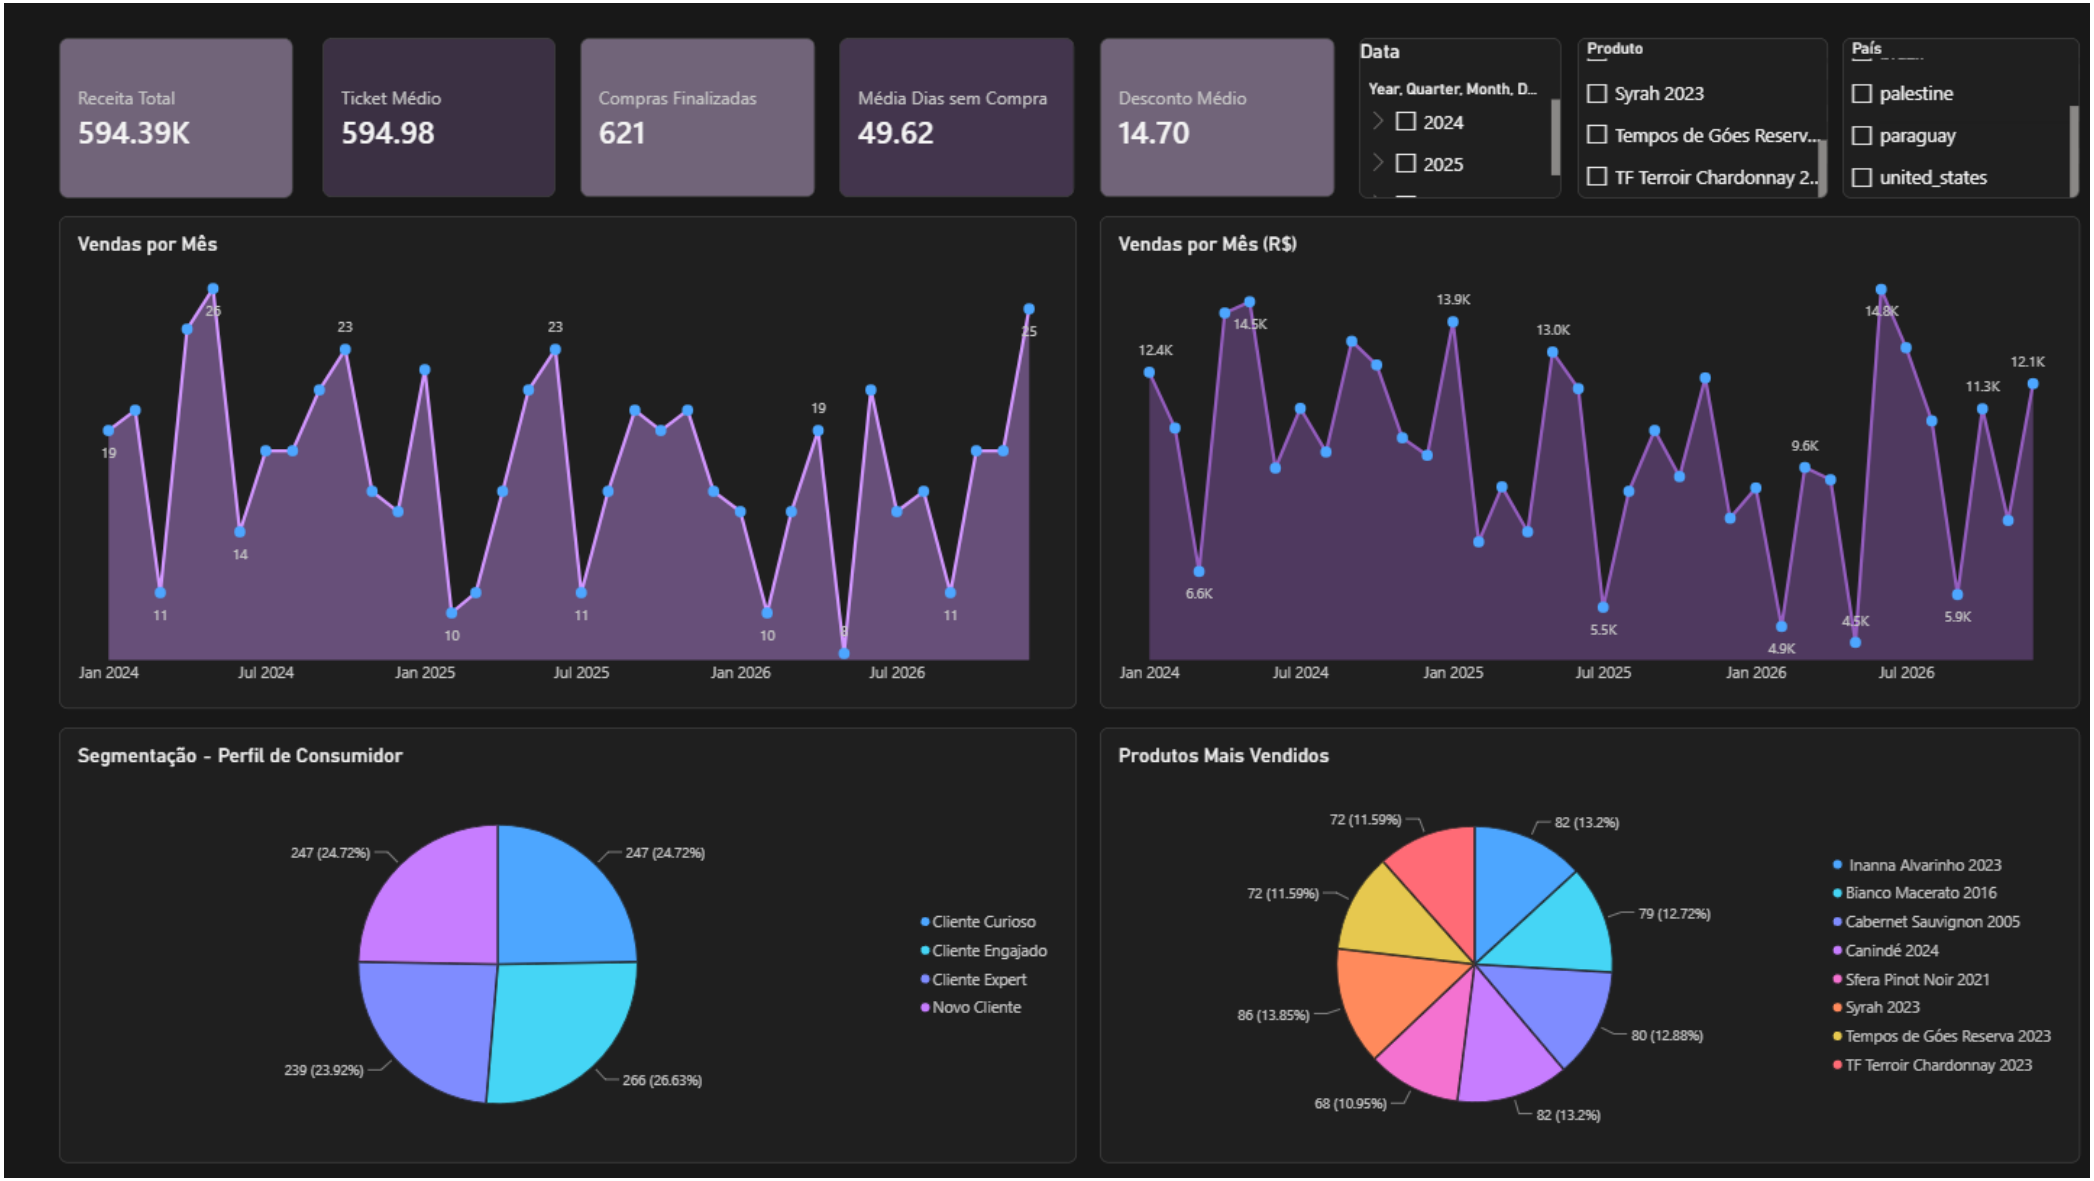


Figura 1. Painel Power BI com 621 compras concluídas no XLSX de referência. Os cartões de valor exibem a soma e a média dos preços finais das 999 tentativas.
Base da modelagem. As métricas da árvore de decisão foram calculadas no CSV oficial.

4. Reflexão final

Quais insights foram descobertos?

O uso do Sommelier teve taxas de conclusão próximas às do grupo sem uso. Foram **264 de 428 (61,68%)** com uso e **355 de 571 (62,17%)** sem uso, uma diferença de -0,49 ponto percentual. Retirar esse indicador manteve as métricas de validação com os mesmos hiperparâmetros. A comparação descreve a amostra simulada e não permite estimar um efeito causal.

O volume e a proporção de conclusão contam histórias diferentes. Os tintos tiveram mais compras concluídas (**312**), mas 59,20% das suas tentativas foram concluídas, ante 65,61% entre os brancos (**166** conclusões).

Como a Vinheria poderia usar a análise?

O painel pode ajudar a acompanhar volume e taxa de conclusão por produto, período e mercado. A equipe pode investigar produtos com muitas tentativas e menor conclusão, e testar o Sommelier em um piloto controlado com clientes reais antes de decidir mudanças no atendimento ou na oferta.

O modelo teve bom desempenho?

A árvore não superou o classificador de referência de forma consistente no teste. O baseline prevê sempre a classe majoritária aprendida no treino. A classe 0 representa tentativas não concluídas.

Métrica no teste	Árvore	Baseline
Acurácia	45,21%	55,71%
Precisão da classe 0	42,38%	0,00%
Recall da classe 0	65,98%	0,00%
F1 macro	0,4423	0,3578
Acurácia balanceada	0,4733	0,5000
ROC-AUC	0,4733	0,5000

A precisão do baseline para a classe 0 foi registrada como zero, pois ele nunca prevê essa classe.

Na planilha de referência, o uso do Sommelier e a conclusão da compra são gerados por sorteios separados. Como o desfecho é sorteado sem usar as características da tentativa, a simulação pode oferecer pouco sinal para a árvore aprender. Pequenas diferenças nas taxas de conclusão podem surgir pelo acaso. Esse desenho limita o que podemos dizer sobre o impacto do Sommelier nas vendas reais.

Embora a árvore reconheça parte das não conclusões, o ROC-AUC próximo de 0,5 indica baixa capacidade de distinguir as classes neste teste. Para melhorar, a Vinheria poderia coletar eventos reais antes da compra, como navegação, ações no carrinho, canal e interações com horário registrado. O próximo modelo deveria ser validado em um período futuro.